■■■

```
    TW --> RM
    CW --> RM
    CP --> RM

    RM --> LLaVA
    RM --> Qwen
    CP --> DB
```

启动方式

```
cd /root/autodl-tmp/vision_qa_platform/agent_workspace
bash webapps_ctl.sh start    # 启动三个服务
bash webapps_ctl.sh status   # 查看状态
```

在 AutoDL 等云平台访问时，需在本机建立 SSH 端口转发（示例）：

```
ssh -p 24484 \
  -L 7860:127.0.0.1:7860 \
  -L 7861:127.0.0.1:7861 \
  -L 7862:127.0.0.1:7862 \
  root@connect.bjb1.seetacloud.com
```

浏览器访问：

- 7860：http://127.0.0.1:7860
- 7861：http://127.0.0.1:7861
- 7862：http://127.0.0.1:7862

二、共享的「四模块推理」是怎么跑的

7860 / 7861 / 7862 的在线问答都走同一套流水线（portal 通过 `vqa_service.py` 复用 webapp 逻辑）。

1. 视觉理解（**LLaVA**）

`VisionToTextReasoner`（`tot_got_integration.py`）用 **LLaVA-1.5-7B** 把图片转成中文视觉描述：

- 模型路径：`llava-1.5-7b-hf`
- 核心方法：`get_visual_description(image_path, question_hint)`
- 流程：PIL 读图 → CLIP 预处理 → LLaVA `generate` → 提取 `ASSISTANT:` 后的中文描述

2. 四模块推理（**Qwen2-1.5B**）

`SearchController.solve()`（`reasoning_modules.py`）串联四个模块：

模块	类	作用
问题分解器	`QuestionDecomposer`	主问题 → 3 个子问题
思维生成器	`ThoughtGenerator`	每个子问题生成 3 条候选（思路 + 答案）
状态评估器	`StateEvaluator`	给候选打分（0.1～1.0）

模块	类	作用
搜索控制器	SearchController	选最高分候选，汇总成最终答案

伪代码流程：

```
sub_questions = decomposer.decompose(visual_description,
question)
for sub_q in sub_questions:
    candidates = generator.generate_candidates(...)
    scores = evaluator.score_candidates(...)
    best_idx = argmax(scores)
    trace.append({ sub_question, candidates, scores,
selected_index })
final_answer = aggregate(selected_sub_answers)
```

3. 答案收敛

`constrained_finalize_answer()`（`vqa_eval_utils.py`）根据视觉描述、原问题和子问题答案，生成最终短答案。

4. 模型单例 + 线程锁

三个服务都用 `_PIPELINE` 全局变量 + `threading.Lock()`，首次请求时加载模型，之后复用，避免重复占 GPU。

涉及模型：

- 视觉：`/root/autodl-tmp/vision_qa_platform/llava-1.5-7b-hf`
- 语言：`/root/autodl-tmp/vision_qa_platform/text_model/qwen2_1_5b_instruct`

三、7860：trace_webapp — 离线轨迹浏览

核心思路：主要读已经跑好的评测 JSON，把 `trace` 字段画成图；也支持上传新图做在线推理。

代码位置

- 后端：`agent_workspace/trace_webapp/app.py`
- 前端：`agent_workspace/trace_webapp/templates/index.html`（单文件，内联 CSS/JS）

数据来源

默认读：

```
/root/autodl-tmp/vision_qa_platform/results/accuracy/
modular_results_complex1000.json
```

可通过环境变量 `TRACE_RESULTS_FILE` 切换。

后端 **API**

接口	作用
`GET /`	渲染主页面
`GET /api/cases`	列出所有样本（问题、预测、真值、对错）
`GET /api/case/<qid>`	单个样本的图结构 + 图片 URL
`GET /api/case/<qid>/image`	返回样本图片
`POST /api/ask`	上传新图 + 问题，在线跑四模块

图结构怎么构建

`build_graph()` 把 JSON 里的 `trace` 转成 D3 用的 `nodes + links`:

```
问题节点
  ├─ 子问题1 ─ 候选1 / 候选2 / 候选3（选中项高亮）
  ├─ 子问题2 ─ ...
  └─ 子问题3 ─ ...
  ├─ 预测节点
  └─ 真值节点（仅离线数据有）
```

节点类型: `question` / `subq` / `candidate` / `candidate_selected` / `pred` / `gt`，前端用不同颜色区分。

前端布局（三栏）

左栏	中栏	右栏
案例列表 + 下拉选择	D3 力导向图（可拖拽、点击看详情）	节点详情 + 新图片问答表单

特点：侧重论文/实验复盘——能对比预测与真值，看每条轨迹里哪个候选被选中。

四、7861: chat_vqa_webapp — 在线问答 Demo

核心思路：聊天式交互 + 右侧实时推理图，无用户系统，适合快速演示。

代码位置

- 后端: `agent_workspace/chat_vqa_webapp/app.py`
- 前端: `agent_workspace/chat_vqa_webapp/templates/index.html`

与 7860 的差异

对比项	7860 trace	7861 chat
主要用途	浏览历史结果	实时问答
登录	无	无
数据持久化	无（刷新即丢）	无
中文化	轨迹多为英文原文	全链路中文化

对比项	7860 trace	7861 chat
布局	三栏（含案例列表）	两栏（聊天 + 图）

中文化处理（7861 独有）

chat_vqa_webapp/app.py 在推理后做大量翻译：

- to_chinese_text()：问题、视觉描述
- to_chinese_answer()：短答案（yes/no → 是/否 等规则映射 + LLM）
- localize_trace_to_chinese()：子问题、候选思路、候选答案批量翻译
- _TRANSLATION_CACHE：避免重复翻译

请求流程

用户上传图片 + 问题
→ POST /api/ask
→ LLaVA 描述图像
→ 四模块推理
→ 中文化
→ 返回 { answer, graph, trace, image_url }
→ 左侧聊天气泡 + 右侧 D3 图

后端 API

接口	作用
GET /	主页面
GET /api/health	健康检查
POST /api/ask	上传图片 + 问题，返回答案与推理图
GET /uploads/<filename>	访问上传的图片

五、7862：chat_vqa_portal — 完整用户版

核心思路：在 7861 的推理能力上，加上账号、会话、历史记录，做成可用的产品形态。

代码位置

文件	职责
chat_vqa_portal/app.py	路由、Session、权限
chat_vqa_portal/auth_utils.py	注册校验、密码哈希
chat_vqa_portal/db.py	MongoDB 文档库（连不上则降级 Mongita 本地 JSON）
chat_vqa_portal/vqa_service.py	与 7861 相同的四模块推理 + 中文化
chat_vqa_portal/templates/	login / register / chat 页面
chat_vqa_portal/static/	CSS、JS（chat.js）

数据库设计

默认尝试连接 `mongodb://127.0.0.1:27017`，库名 `vision_qa_portal`；若 MongoDB 未启动，数据写入 `mongo_data/`（Mongita）。

三个集合：

集合	存什么
`users`	username, email, password_hash, created_at
`conversations`	user_id, title, created_at, updated_at
`messages`	conversation_id, role, content, image_path, answer, **graph**, trace, visual_description

问答时会把推理图 **`graph`** 一并入库，刷新后还能点开历史消息看 D3 图。

认证流程

- Flask `session` + `secret_key`（环境变量 `PORTAL_SECRET_KEY`）
- `@login_required` 装饰器：未登录访问 `/api/*` 返回 401，页面跳转 `/login`
- 注册：`POST /api/auth/register`
- 登录：支持用户名或邮箱，`POST /api/auth/login`
- 退出：`POST /api/auth/logout`

会话 API

接口	作用
`GET /api/conversations`	左侧会话列表
`POST /api/conversations`	新建对话
`GET /api/conversations/<id>/messages`	加载历史消息
`POST /api/conversations/<id>/ask`	上传图＋问题，推理并入库
`DELETE /api/conversations/<id>`	删除对话
`GET /api/auth/me`	当前用户信息

前端布局（**GPT** 风格三栏）

左栏	中栏	右栏
会话列表 ＋ 新对话 ＋ 退出	消息区 ＋ 输入框	D3 推理图 ＋ 节点详情

`chat.js` 主要逻辑：

1. 启动时 `loadConversations()` 拉会话列表
2. 点会话 → 加载历史消息，助手消息带 `graph` 可点击
3. 发送 → `FormData` 上传图片 → `/api/conversations/<id>/ask`
4. 返回后追加气泡 + `renderGraph()`

图片按用户隔离：`uploads/<user_id>/<filename>`，访问时校验 `user_id == session`。

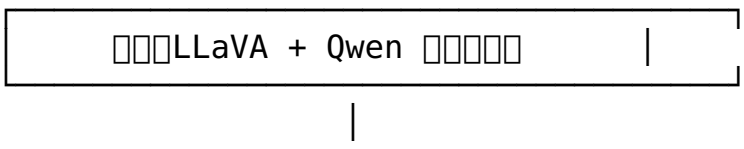

环境变量

变量	说明	默认
PORTAL_PORT	服务端口	7862
MONGO_URI	MongoDB 连接串	mongodb://127.0.0.1:27017
PORTAL_SECRET_KEY	Flask 会话密钥	开发用默认值（生产请修改）

六、D3 推理图（三个界面共用思路）

三个前端都用 **D3.js v7** 力导向图（CDN: https://cdn.jsdelivr.net/npm/d3@7）。

共同渲染模式

```
nodes = [{ id, label, type, detail }, ...]
links = [{ source, target }, ...]

d3.forceSimulation(nodes)
  .force("link", d3.forceLink(links).id(d => d.id))
  .force("charge", d3.forceManyBody())       // 节点互斥
  .force("center", d3.forceCenter(...))       // 居中
  .force("collision", d3.forceCollide())     // 防重叠（7860/7861）

// 圆点 + 文字标签 + 拖拽 + 点击显示 detail JSON
```

节点颜色映射

类型	颜色	含义
question	青色 #22d3ee	主问题
subq	橙色 #f59e0b	子问题
candidate	蓝色 #60a5fa	未选中候选
candidate_selected	绿色 #34d399	选中候选
pred	紫色 #a78bfa	最终答案
gt	红色 #f43f5e	真值（仅 7860 离线）

交互

- 拖拽: d3.drag() 固定节点位置
- 点击节点: 右侧面板显示 detail 字段 JSON（子问题文本、候选思路、评分等）

七、三者关系总结

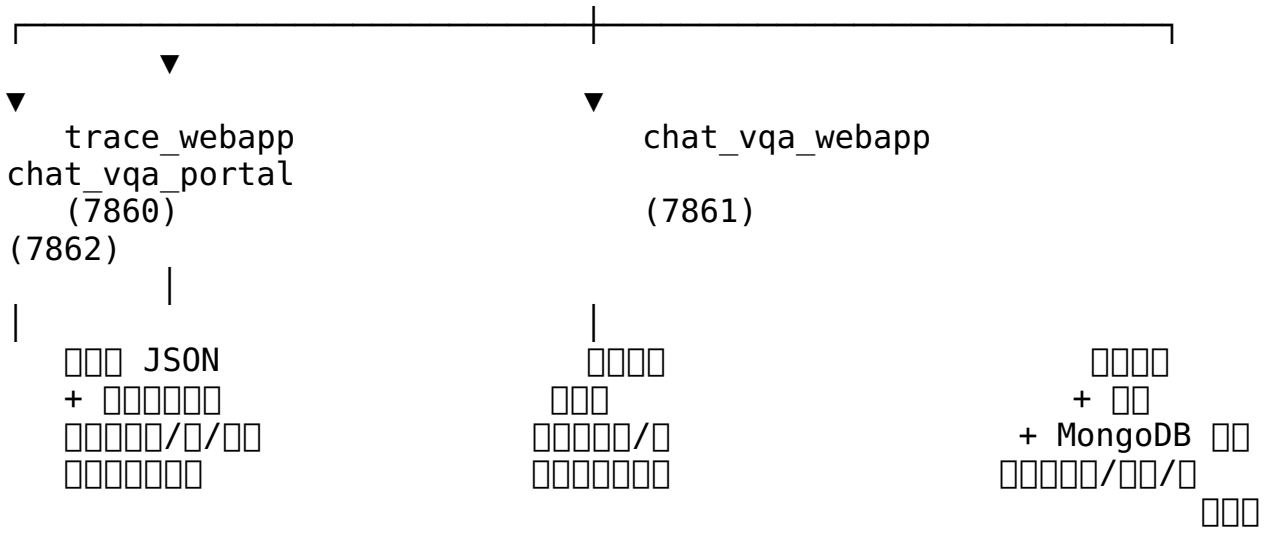

7860 =
7861 = ChatGPT +
7862 = 7861

---

agent_workspace/webapps_ctl.sh	
agent_workspace/trace_webapp/app.py	7860
agent_workspace/chat_vqa_webapp/app.py	7861
agent_workspace/chat_vqa_portal/app.py	7862
reasoning_modules.py	
tot_got_integration.py	LLaVA + Qwen
vqa_eval_utils.py	
results/accuracy/modular_results_complex1000.json	7860

2026-05-29